

1.ΠΡΟΣΕΓΓΙΣΗ

→ Φόρτωση – Μελέτη υφιστάμενου συνόλου GreekLegalSum:

- Φόρτωσα το dataset DominusTea/GreekLegalSum με datasets.load_dataset, κατέγραψα τη διάταξη των fields και επιβεβαίωσα ότι δεν περιέχει αποφάσεις του 2024.
- Με ένα regex εξήγαγα το έτος κάθε απόφασης, για να δω ακριβώς ποια χρονικά κενά καλύπτω.

→ Σχεδιασμός σχήματος δεδομένων (A1):

- Το dataset μου έχει columns: decision_number, decision_year, section_type (“ΠΟΙΝΙΚΕΣ” ή “ΠΟΛΙΤΙΚΕΣ”), section_number, court_intro, hearing_date, publication_date, judges, skefthike, gia_tous_logous, penal_code_articles, penal_proc_articles, civil_code_articles, civil_proc_code_articles, url.(έβαλα αυτά που μας ζητούνται καθώς και μερικά δικά μου τα οποία θα αναλυθούν στις προδιαγραφές)
- Για κενές τιμές χρησιμοποίησα None ή κενές λίστες.

→ Ανάπτυξη ανιχνευτή (crawler) (A2):

- Ο κώδικας χωρίζεται σε τρία αρχεία: client (HTTP), scraper (links) και parser (fields).
- Ξεκινάω με requests.Session, βάζω custom User-Agent και ενεργοποιώ logging.
- Η συνάρτηση get_soup κατεβάζει HTML, μετατρέπει από windows-1253 σε UTF-8 και επιστρέφει BeautifulSoup· αν αποτύχει, γράφω warning και συνεχίζω.
- Η get_all_2024_links κάνει POST στο apofaseis_result.asp (year = 2024), κρατά μόνο ΠΟΛΙΤΙΚΕΣ ή ΠΟΙΝΙΚΕΣ αποφάσεις, χτίζει το τελικό URL, κάνει dedup και εκτυπώνει πόσα unique URLs βρήκα.Γεμίζει επίσης τα πεδία decision_year, section_type, section_number, μέσω του html της σελίδας.
- Για κάθε URL η parse_decision_page γεμίζει τα πεδία: court_intro, decision_number, decision_year, hearing_date, publication_date, judges, skefthike, gia_tous_logous. Το gia_tous_logous σταματά πριν από τη γραμμή δημοσίευσης.
- Η extract_articles βρίσκει parenthetical ή inline αναφορές (π.χ. (80, 81 ΚΠΔ) ή “άρθρο 361 ΠΚ”), κανονικοποιεί και επιστρέφει μοναδική λίστα. Ανάλογα με section_type γεμίζω penal_code_articles, penal_proc_articles, civil_code_articles και civil_proc_code_articles.
- Το logging κρατά trace επιτυχημένων και αποτυχημένων λήψεων περίπου πέντε URLs δεν φορτώνονται, κάτι που αποδίδω στον server.

→ Αποθήκευση & σύγκριση (A3):

- Τύπωσα δείγμα 10 γραμμών από το training split του 2018 μόνο για να δω columns και types και να τα συγκρίνω με το δικό μου schema.

→ Ανάλυση & οπτικοποίηση (A4):

- Παρήγαγα bar ή line charts για πλήθος αποφάσεων ανά τμήμα και ανά μήνα, horizontal

bars για top judges και bar charts για τα 10 συχνότερα άρθρα σε κάθε κώδικα.

- Δεν έφτιαξα άλλα chart types γιατί δεν υπήρχε κάποια σημαντική σχέση συσχέτισης που να το δικαιολογεί τα βασικά bar/line απαντούν επαρκώς στις ερωτήσεις του project.

2.ΠΡΟΔΙΑΓΡΑΦΕΣ

- decision_number : int – ακέραιος αριθμός απόφασης, π.χ. 11
- decision_year : int – έτος έκδοσης, π.χ. 2024
- section_type : string – «ΠΟΙΝΙΚΕΣ» ή «ΠΟΛΙΤΙΚΕΣ» (κεφαλαία)
- section_number : string – κωδικός τμήματος, π.χ. «B1»· μπορεί να είναι None αν δεν υπάρχει
- court_intro : string – σύντομος τίτλος τμήματος, π.χ. «B1' Πολιτικό Τμήμα»
- hearing_date : string – ημερομηνία που συνήλθε η απόφαση σε μορφή «30 Ιουνίου 2022» ή None
- publication_date : string – ημερομηνία δημοσίευσης σε μορφή «5 Ιανουαρίου 2024» ή None
- judges : list[string] – ονόματα/βαθμοί δικαστών, π.χ. ["Λουκά Μόρφη", "Αντιπρόεδρος του Αρείου Πάγου"]
- skefthike : string – πλήρες κείμενο από «ΣΚΕΦΘΗΚΕ ΣΥΜΦΩΝΑ ΜΕ ΤΟ ΝΟΜΟ» έως πριν το «ΓΙΑ ΤΟΥΣ ΛΟΓΟΥΣ ΑΥΤΟΥΣ» None σε πράξεις χωρίς σκεπτικό
- gia_tous_logous : string – κείμενο από «ΓΙΑ ΤΟΥΣ ΛΟΓΟΥΣ ΑΥΤΟΥΣ» έως πριν τη γραμμή δημοσίευσης· None αν δεν υπάρχει διατακτικό
- penal_code_articles : list[string] – άρθρα Ποινικού Κώδικα (π.χ. "άρθρο 361"), κενή λίστα αν δεν εντοπίστηκαν
- penal_proc_articles : list[string] – άρθρα Κώδικα Ποινικής Δικονομίας, κενή λίστα αν δεν εντοπίστηκαν
- civil_code_articles : list[string] – άρθρα Αστικού Κώδικα, κενή λίστα αν δεν εντοπίστηκαν
- civil_proc_code_articles : list[string] – άρθρα Κώδικα Πολιτικής Δικονομίας, κενή λίστα αν δεν εντοπίστηκαν
- url : string – μόνιμος σύνδεσμος της απόφασης, π.χ. https://areiospagos.gr/nomologia/apofaseis_DIS...

Όλες οι τιμές είναι UTF-8· τα πεδία επιτρέπουν None ή κενή λίστα όπου το αντίστοιχο στοιχείο απουσιάζει.

3.ΑΝΑΛΥΣΗ ΚΩΔΙΚΑ(CRAWL-PARSE):

Ξεκίνησα ανοίγοντας τη σελίδα αναζήτησης του Αρείου Πάγου, πάτησα Ctrl-U, διάβασα το raw HTML και εντόπισα πού κρύβονται οι σύνδεσμοι με τις αποφάσεις. Στη συνέχεια

διάβασα αρκετές αποφάσεις, σε πολιτικό και ποινικό τμήμα, για να καταγράψω όλες τις συντακτικές παραλλαγές και να συγκεντρώσω τα keywords που χρειάζομαι στον parser. Από αυτή τη χειροκίνητη δουλειά προέκυψαν δύο βασικές ρουτίνες: `get_all_2024_links` (scraper) και `parse_decision_page` (parser).

→ HTTP client & βοηθητικά

- Δημιούργησα ένα `requests.Session` και όρισα User-Agent τύπου browser, ώστε ο server να με θεωρεί «κανονικό» χρήστη.
- Ενεργοποίησα logging σε επίπεδο INFO για να βλέπω progress και προειδοποιήσεις.
- Η `get_soup` κάνει GET με timeout 10 s, ορίζει encoding σε windows-1253 (αλλιώς τα ελληνικά χαλάνε), ελέγχει status και επιστρέφει BeautifulSoup • αν υπάρξει σφάλμα, γράφει warning και επιστρέφει None.

→ `get_all_2024_links` – scraper

- Στήνω payload που μιμείται τη φόρμα: `x_ETOS = 2024`, `x_TMHMA = 6` (όλες οι βάσεις).
- Στέλνω POST στο `apofaseis_result.asp` και παίρνω τη σελίδα αποτελεσμάτων.
- Με τη BeautifulSoup βρίσκω όλα τα `<a>` των οποίων το href περιέχει `apofaseis_DISPLAY`.
- Από το ορατό κείμενο «αριθμός / 2024» κόβω `decision_number` και `decision_year`.
- Με `urlparse` διαβάζω την παράμετρο `info` για να πάρω:
 - `section_type` («ΠΟΙΝΙΚΕΣ» ή «ΠΟΛΙΤΙΚΕΣ»)
 - `section_number` (π.χ. «B1»), είτε χωρίζοντας σε «B1, ΠΟΛΙΤΙΚΕΣ» είτε «ΠΟΙΝΙΚΕΣ-Δ».
- Χτίζω το τελικό `detail_url`:
`apofaseis_DISPLAY.asp?cd=<hash>&apof=<αριθμός>_<έτος>`.
- Αποφεύγω διπλοεγγραφές με ένα set περιλαμβάνοντας μόνο το πρώτο url· στο τέλος τυπώνω πόσα unique urls βρέθηκαν.

→ `extract_articles` – helper

- Κατέγραψα δύο βασικά pattern παραπομπών:
 1. Παρενθετικό («(80, 81 ΚΠΔ)» ή «(ΚΠολΔ 68, 622)»)
 2. Inline «άρθρο 361 ΠΚ».
- Αντιμετώπισα το συχνό μπέρδεμα ελληνικού «Κ» με λατινικό “K” κάνοντας κανονικοποίηση (Δεν ξέρω γιατί βρίσκεται λατινικό K στο site του Άρειου Πάγου!!).
- Ο πρώτος regex βρίσκει παραπομπές τύπου «(80, 81 ΚΠΔ)» και «(ΚΠολΔ 68, 622)» σε μία κίνηση, ενώ ο δεύτερος ψάχνει για τη λέξη «άρθρο» και ελέγχει αν, μέσα στα επόμενα 50 γράμματα, εμφανίζεται κάποιο ακρωνύμιο κώδικα.
- Σπάω λίστες «80, 81», κανονικοποιώ «παρ.», αφαιρώ διπλοεγγραφές και επιστρέφω σειρά εμφάνισης.
- Ψάχνω πρώτα στο block ΣΚΕΦΘΗΚΕ μετά στο ΓΙΑ ΤΟΥΣ (νόμιμο σκεπτικό) κι αν δεν βρω, σαρώνω όλο το κείμενο.

→ `parse_decision_page` – parser

1. Καθαρίζω ειδικές περιπτώσεις «ΤΟ ΔΙΚΑΣΤΗ ΡΙΟ» → «ΤΟ ΔΙΚΑΣΤΗΡΙΟ»· τραβάω αμέσως τη court_intro.
 2. Το court_intro το τραβάω απλώς από τη γραμμή που ακολουθεί αμέσως μετά το keyword «ΤΟ ΔΙΚΑΣΤΗΡΙΟ ΤΟΥ ΑΡΕΙΟΥ ΠΑΓΟΥ».
 3. hearing_date με regex «Συνήλθε ... στις <ημερομηνία>».
 4. publication_date ψάχνοντας λέξεις-κλειδιά «Δημοσιεύθηκε | ΔΗΜΟΣΙΕΥΘΗΚΕ | Εκδόθηκε» + «στις/την <ημερομηνία>».
 5. judges με pattern «Συγκροτήθηκε από ... τους Δικαστές ...» μέχρι «Αρεοπαγίτες», μετά split σε κόμμα/ερωτηματικό.
 6. skefthike = block από «ΣΚΕΦΘΗΚΕ ΣΥΜΦΩΝΑ ΜΕ ΤΟ ΝΟΜΟ» μέχρι πριν «ΓΙΑ ΤΟΥΣ» ή «ΔΙΑΤΑΓΗ».
 7. gia_tous_logous = block «ΓΙΑ ΤΟΥΣ ΛΟΓΟΥΣ ΑΥΤΟΥΣ» μέχρι πριν τον marker δημοσίευσης· έτσι δεν παίρνω ημερομηνία ούτε υπογραφές.
- Αν section_type είναι ΠΟΙΝΙΚΕΣ, καλώ extract_articles με ΠΚ / ΚΠΔ· αν είναι ΠΟΛΙΤΙΚΕΣ, με ΑΚ / ΚΠολΔ.
 - Ό,τι δεν βρεθεί παραμένει None ή κενή λίστα.

4. ΑΝΑΛΥΣΗ-ΣΥΓΚΡΙΣΗ ΔΕΔΟΜΕΝΩΝ

Το GreekLegalSum περιέχει επτά στήλες.

Η στήλη text κρατά ολόκληρη την απόφαση σε ένα ενιαίο κείμενο· μέσα της βρίσκονται ο αριθμός, η επικεφαλίδα, οι ημερομηνίες, τα ονόματα δικαστών, το σκεπτικό και το διατακτικό.

Η summary είναι μια σύντομη, ανθρώπινη περίληψη που περιγράφει σε δυο-τρία σκόπιμα πυκνά σημεία τι αποφάσισε το δικαστήριο και γιατί.

Η case_category δίνει έναν γενικό νομικό χαρακτηρισμό, π.χ. «Αβάσιμοι λόγοι», ενώ η case_tags παρέχει λεπτομερέστερες ετικέτες με κόμμα, όπως «Απάτη, Αναιρέσεως απόρριψη».

Η subset είναι απλώς αριθμός που δείχνει αν η εγγραφή ανήκει σε train, validation ή test.

Τέλος, οι decision_year και year αποθηκεύουν το ίδιο έτος που εξήγαγαν οι δημιουργοί του συνόλου από το πλήρες κείμενο· το δεύτερο αντιγράφεται μόνο για λόγους συμβατότητας.

Όταν συγκρίνω αυτά τα πεδία με το δικό μου DataFrame για το 2024, προκύπτουν λίγα σημεία επικάλυψης.

Το GreekLegalSum text συγκεντρώνει σε μία συμβολοσειρά ό,τι εγώ κατέγραψα διακριτά: decision_number, decision_year, section_type, section_number, court_intro, skefthike, gia_tous_logous, τις ημερομηνίες και τους δικαστές.

Η summary αντιστοιχεί λειτουργικά στο δικό μου gia_tous_logous· και οι δύο στήλες δείχνουν τι αποφασίστηκε, όμως η summary είναι σύντομο παράφρασμα, ενώ το δικό μου πεδίο περιέχει ολόκληρο το αυθεντικό διατακτικό.

Τα decision_year και year ταυτίζονται με το δικό μου decision_year και με το έτος που

περιέχεται στο `publication_date`.

Όλα τα άλλα στοιχεία που προσθέτω εγώ—ημερομηνία συζήτησης, πλήρης λίστα δικαστών, καθώς και οι τέσσερις λίστες άρθρων ΠΚ, ΚΠΔ, ΑΚ, ΚΠολΔ—δεν υπάρχουν πουθενά στο `GreekLegalSum`.

Περίμενα ότι το `GreekLegalSum` θα μου πρόσφερε τουλάχιστον:

- ξεχωριστά πεδία για αριθμό απόφασης, τμήμα και ημερομηνίες αντί να τα κρύβει όλα μέσα στο ίδιο `text`.
- κάποιο πεδίο με τους δικαστές ή έστω τον πρόεδρο του σχηματισμού.
- λίστα με τα άρθρα των κωδίκων που επικαλείται η απόφαση, ώστε να μη χρειάζεται δικό μου `regex`.
- πεδία τύπου `hearing_date` ή `publication_date` για ακριβή χρονολογία.

Με άλλα λόγια, περίμενα ξεκάθαρο, δομημένο μετα-δεδομένο που να επιτρέπει φιλτράρισμα χωρίς πρόσθετο `parsing` τελικά βρήκα κυρίως ένα ενιαίο κείμενο και μια σύντομη περίληψη.

5. ΟΠΤΙΚΟΠΟΙΗΣΗ

Στα γραφήματά μου στηρίχθηκα κυρίως σε διάφορες παραλλαγές `bar chart`—ομαδοποιημένες, στοιβαγμένες, οριζόντιες—επειδή αυτό προτείνουν τα περισσότερα φροντιστήρια οπτικοποίησης δεδομένων, αλλά όχι μόνο γι' αυτό. Τα `bar charts` εξυπηρετούν ακριβώς τον στόχο μου: να συγκρίνω απόλυτα μεγέθη (πλήθος αποφάσεων ανά τμήμα, ανά μήνα, κορυφαίους δικαστές, συχνότητα άρθρων) χωρίς να φορτώνω τον αναγνώστη με περιττή πολυπλοκότητα. Κρατούν τον άξονα μέτρησης καθαρό, διαβάζονται άμεσα και—με μια συνεπή, δίχρωμη παλέτα για «ΠΟΙΝΙΚΕΣ» και «ΠΟΛΙΤΙΚΕΣ»—γίνονται φιλικά στο μάτι ακόμη και για έναν μη ειδικό. Με άλλα λόγια, διάλεξα το εργαλείο που μου είναι πιο γνώριμο, αλλά και με αυτό είμαι σχεδόν βέβαιος ότι αποδίδει το μήνυμά με τον πιο κατανοητό και κομψό τρόπο. Όσον αφορά την περιγραφή των `plots` και το τι παρουσιάζει το καθένα ξεχωριστά είναι πολύ απλό να το καταλάβει κανείς οπότε δεν θα περιττολογήσω περισσότερο εδώ πέρα, καθώς υπάρχουν και επίσης πολλά βοηθητικά σχόλια μέσα στο `notebook` που εξηγούν σε βάθος τι οπτικοποιείται.