

Project B

Ονοματεπώνυμο-Α.Μ. : Περικλής Παύλου-3220158

B1.

i.ii.iii.

→Χρησιμοποιήσαμε αρχικά αναπαραστάσεις Bag-of-Words και TF-IDF μόνα τους και μαζί σε ένα pipeline, σε συνδυασμό με έναν γραμμικό ταξινομητή SVM, ώστε να αποκτήσουμε ένα γρήγορο baseline και να κατανοήσουμε εύκολα τον ρόλο των χρονοσειρών n-grams και της στάθμισης TF-IDF. Στη συνέχεια αποφασίσαμε να μεταβούμε σε πιο πλούσιες, dense αναπαραστάσεις κειμένου, εκπαιδεύοντας ένα μοντέλο Word2Vec πάνω στο σύνολο των εγγράφων. Η επιλογή του Word2Vec έγινε γιατί συνδυάζει ευελιξία στην αντιστοίχιση σπανίων λέξεων με καλή γενίκευση, χωρίς να απαιτεί έτοιμα εξωτερικά αρχεία.

→Για την ταξινόμηση δοκιμάσαμε δύο διαφορετικά μοντέλα πάνω στις Word2Vec embeddings: έναν πολυωνυμικό Logistic Regression και ένα πολυστρωματικό νευρωνικό δίκτυο (MLP). Και τα δύο έδειξαν σταθερά καλύτερες μετρικές (accuracy, precision, recall, F1) σε σχέση με το Random Forest, Naïve Bayes και γενικά τις άλλες επιλογές. Ο Logistic Regression μας έδωσε ένα ισορροπημένο performance με ελάχιστη υπερπροσαρμογή, ενώ το MLP κατάφερε να συλλάβει πιο σύνθετα μοτίβα στο χώρο των embeddings, αποδίδοντας ελαφρώς υψηλότερες μετρικές.

→Θα μπορούσαμε να βελτιώσουμε περαιτέρω τις ποιότητες των Word2Vec embeddings αυξάνοντας το πλήθος των εποχών εκπαίδευσης ή αλλάζοντας άλλα hyperparameters, όμως η εκπαίδευση των 400-διάστατων διανυσμάτων ήδη απαιτούσε περίπου μιάμιση ώρα σε διαθέσιμο hardware. Λόγω περιορισμένου χρόνου στη δουλειά μου, προτιμήσαμε να προχωρήσουμε με τα embeddings που είχαμε, ώστε να ολοκληρώσουμε την αξιολόγηση των μοντέλων εγκαίρως, παρά να παρατείνουμε υπερβολικά τη διαδικασία για μικρά επιπλέον κέρδη.

B2.

i. Στα Pareto διαγράμματα έχουμε εικονογραφήσει μόνο τις 20 κορυφαίες κατηγορίες και ετικέτες αντίστοιχα, γιατί το πλήθος τους στο σύνολο των αποφάσεων είναι πολύ μεγαλύτερο αν εμφανίζαμε όλες μαζί, το γράφημα θα γινόταν όχι μόνο δυσανάγνωστο αλλά και σχεδόν άχρηστο για εξαγωγή συμπερασμάτων. Με αυτή την επιλογή, βλέπουμε ξεκάθαρα ότι μια μικρή πλειοψηφία θεματικών ενοτήτων καλύπτει ένα μεγάλο μέρος του συνόλου: για παράδειγμα, οι τρεις πρώτες κατηγορίες μαζί αντιστοιχούν στο 50 % περίπου των αποφάσεων, ενώ οι είκοσι πρώτες συγκεντρώνουν γύρω στο 80 %. Παρόμοια, για τις ετικέτες ("case tags") διαφαίνεται ότι μόλις με είκοσι σημασιολογικά ονόματα φτάνουμε σε ένα σημαντικό ποσοστό της συνολικής σήμανσης η υπόλοιπη «ουρά» των ετικετών είναι πολύ πιο αραιή και έχει μακρύ «long tail». Αυτό μας δείχνει πως, παρά τη θεματική ποικιλία των αποφάσεων, υπάρχουν μερικά επαναλαμβανόμενα μοτίβα στους τίτλους και στις τάξεις θεμάτων που ορίζουν οι χρήστες. Τέλος, παρατηρήσαμε ότι αρκετά από τα ονόματα που εμφανίζονται ως «case category» είναι σχεδόν τα ίδια με ορισμένες από τις «case tags» (π.χ. «Αιτιολογία επίδικης», «Ακύρωση απόφασης», «Υπέρβαση εξουσίας» κ.ά.). Επιβεβαιώσαμε χειροκίνητα ότι αυτή η

επικάλυψη δεν οφείλεται σε σφάλμα στον κώδικα, αλλά αντανακλά πραγματικά κοινά θεματικά labels που χρησιμοποιούνται και στις δύο στήλες.

ii. Φορτώνουμε τις περιλήψεις και τις συνοδευτικές κατηγορίες και ετικέτες μετατρέποντας τις κατηγορίες και την πρώτη ετικέτα σε αριθμητικές τιμές για αξιολόγηση. Δημιουργούμε κείμενα εμπλουτισμένα με context προσθέτοντας μπροστά σε κάθε περιήληψη ετικέτες σε μορφή :[κατηγορία: ...] [ετικέτες: ...]

Μετατρέπουμε αυτά τα κείμενα σε διανύσματα tf-idf με n-grams έως 3, φιλτράροντας πολύ συχνές ή πολύ σπάνιες λέξεις, και μειώνουμε τις διαστάσεις τους σε 100 με truncated SVD.

Κανονικοποιήσαμε τα tf-idf–LSA διανύσματα ώστε η απόσταση να είναι cosine και τρέξαμε k-means για k από 2 έως 79 υπολογίζοντας για κάθε k το silhouette micro, το silhouette macro και το NMI σε σχέση με τις πραγματικές κατηγορίες και ετικέτες. Στο διάγραμμα των μετρικών διαπιστώσαμε ότι το NMI για τις κατηγορίες φτάνει περίπου στο 0,56 και για τις ετικέτες στο 0,53 γύρω από το $k = 14$, ενώ το silhouette micro για $k = 14$ είναι περίπου 0,168 και το silhouette macro περίπου 0,292, τιμές που παραμένουν χαμηλές αλλά δεν αυξάνουν σημαντικά για μεγαλύτερα k, και σε μικρότερα k οι συστάδες χάνουν σημαντικό μέρος της ποικιλίας των ετικετών και των κατηγοριών. Για αυτούς τους λόγους επιλέγουμε $k = 14$ ως το σημείο ισορροπίας όπου η αντιστοιχία με τις πραγματικές ετικέτες (NMI) είναι υψηλή χωρίς να θυσιάζεται η συνοχή και η διαχωριστικότητα των συστάδων (silhouette). Εδώ να σημειωθεί ότι όποια αλλαγή και αν σκεφτόμουν το silhouette δυστυχώς δεν αυξανόταν.

iii. Με το LLM ολοκληρώνουμε κάθε υπο-βήμα του ερωτήματος iii) ως εξής: αρχικά εγκαθιστούμε και φορτώνουμε το Llama-Krikri-8B-Instruct μέσα από την Unsloth, ρυθμίζοντας το μοντέλο για inference σε μικρότερης κλίμακας GPU. Στη συνέχεια μετατρέπουμε τα έτοιμα κείμενα σε tf-idf και εφαρμόζουμε K-means για να δημιουργήσουμε K ομάδες αποφάσεων.

Για κάθε ομάδα αποφάσεων συγκεντρώνουμε τρία δείγματα: είτε επιλέγουμε τυχαία τρία δείγματα μέσα από το cluster, είτε παίρνουμε τα τρία πιο κοντινά στο κεντροειδές τους. Κατασκευάζουμε ένα 3-shot prompt όπου περιλαμβάνουμε τα τρία παραδείγματα και το κείμενο-στόχο, με οδηγία «Απάντησε ακριβώς με Θέμα: <τίτλος σε έως 10 λέξεις>». Όταν το μοντέλο επιστρέψει την απάντησή του, χρησιμοποιούμε απλή κανονική έκφραση για να απομονώσουμε τη γραμμή που αρχίζει από «Θέμα:» και παίρνουμε τον παραγόμενο τίτλο. Τέλος, συγκρίνουμε αυτούς τους τίτλους με τις πραγματικές περιλήψεις, μετρώντας πόσες φορές έχουμε ακριβή ταύτιση και υπολογίζοντας το similarity ratio.

Η διαδικασία μας, συνοπτικά, περιλαμβάνει:

1. Προετοιμασία & Clustering: Μετατρέπουμε κάθε απόφαση σε αριθμητική αναπαράσταση και τρέχουμε K-means.
2. Επιλογή examples: Φτιάχνουμε δύο στρατηγικές δειγματοληψίας (τυχαία vs. κεντροειδής).
3. 3-Shot Prompting: Ενώνουμε τα δείγματα σε ένα σύντομο prompt με την εντολή «Θέμα:».

4. Generation & Extraction: Καλούμε το LLM, παίρνουμε την έξοδο και με regex εξάγουμε τον τίτλο.
5. Αξιολόγηση: Μετρικές exact match και similarity ratio για να συγκρίνουμε τις δύο μεθόδους δειγματοληψίας και να επιλέξουμε τη σταθερότερη.

Με αυτό το pipeline καλύπτουμε από την ομαδοποίηση και το σχεδιασμό του prompt, μέχρι την παραγωγή τίτλων και την ποσοτική τους αξιολόγηση.